

Entrega e Implantação Contínuas

Aula 11 · Bloco 3 — Do Código à Produção

Quem decide que vai, quando vai — e para quantos clientes de cada vez

🎯 Nesta aula

1. **Pronto não é no ar**: entrega contínua × implantação contínua
2. Os **ambientes**: o mesmo artefato, outra configuração
3. **Todos de uma vez**: o raio da explosão
4. **Quatro maneiras de pôr no ar** — e o banco de dados
5. **Feature flag**: no ar não é ligado
6. **Escolher pelo risco**, medir pelo DORA

Três decisões, três momentos

publicar

sexta, 18h: a v2.5.0 fica pronta, com tag e CHANGELOG

quem decide: o time

→

implantar

terça, 10h: a v2.5.0 roda em produção, com o cupom **desligado**

quem decide: o time, ou o pipeline

→

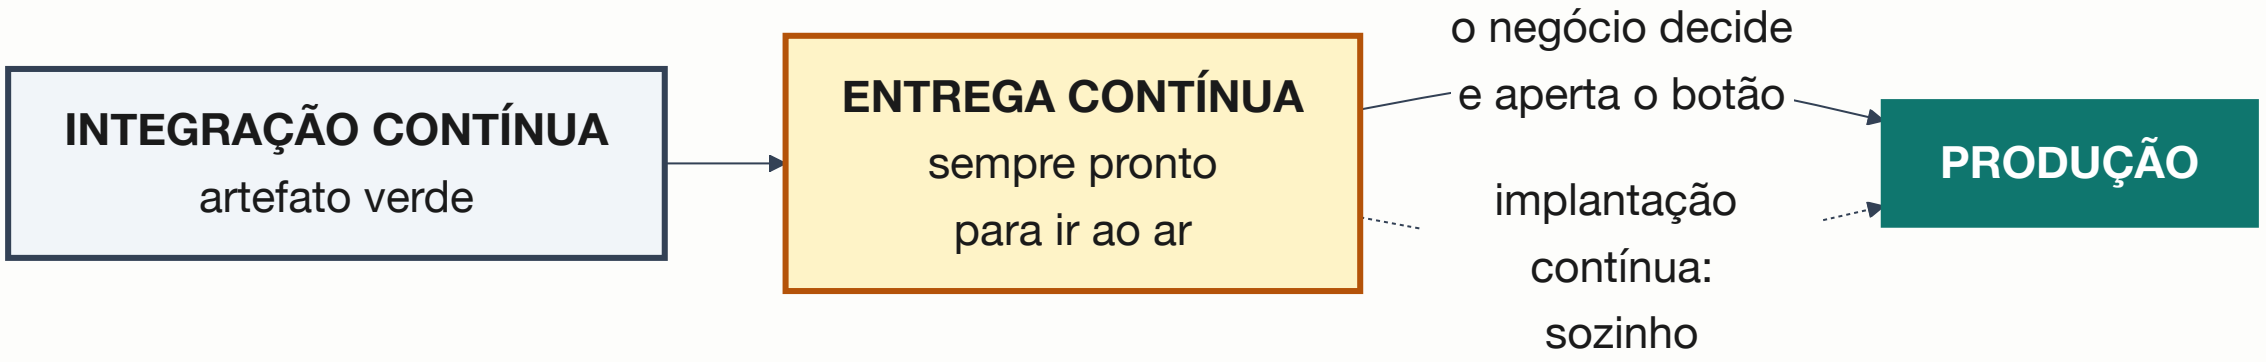
liberar

quarta: o cupom ligado para 10% dos clientes

quem decide: o negócio

A separação veio da Aula 09. Quando as três acontecem no mesmo instante, **cada problema de uma vira problema das outras**.

Entrega contínua × implantação contínua



Entrega contínua

o sistema está **sempre pronto**; ir ao ar é um botão, apertado quando o negócio decide

Implantação contínua

toda mudança que passa no pipeline **vai ao ar sozinha** — a regra foi decidida antes

Fowler: para fazer implantação contínua, **é preciso** fazer entrega contínua. O teste: *"põe no ar a versão de agora"* — dá para fazer já, com segurança?

"O negócio não aceita mudança todo dia"

A frase recusa a **implantação** contínua —
não a **entrega** contínua.

O **prontuário** integra todo dia e está sempre pronto.
O comitê aprova uma **tag**, uma vez por mês,
e a implantação vira um botão numa terça de manhã.

O **delivery** pode ir sozinho ao ar —
menos de sexta a domingo, das 18h às 23h.

Mudança pequena é mudança segura

A cada três meses

- **200** mudanças em cada implantação
- se der errado, a causa está entre 200, de 20 pessoas
- voltar desfaz três meses de trabalho
- o time pratica **4 vezes por ano**

Todo dia

- **3** mudanças em cada implantação
- a causa está entre 3, de ontem, de quem lembra
- voltar desfaz um dia
- o time pratica **todo dia**

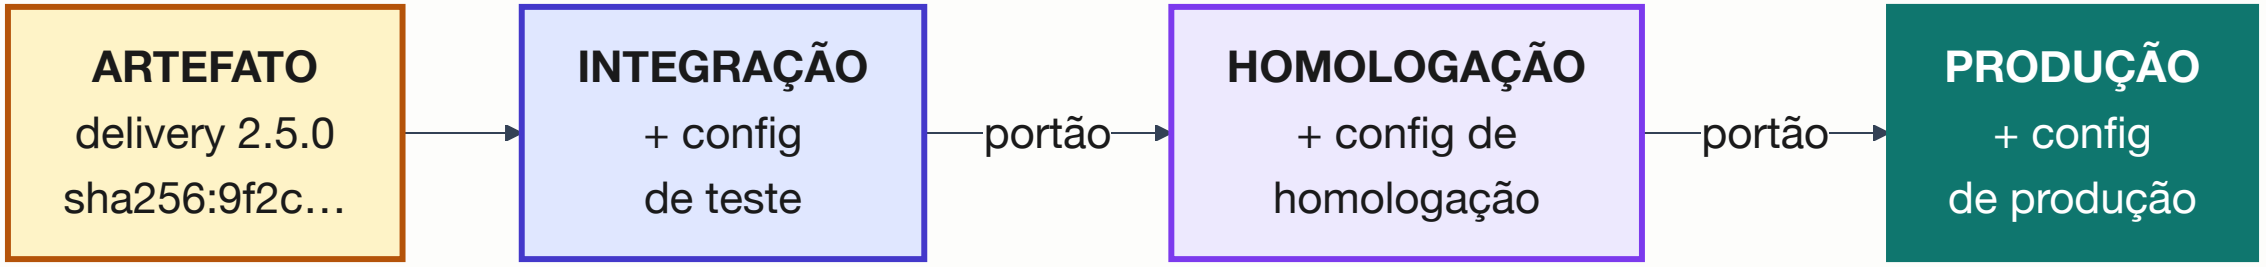
É o ramo longo da Aula 09 e as **mudanças pequenas** do DORA na Aula 10. A implantação ideal é um **não-evento**.

Os ambientes até a produção

desenvolvimento	funciona isolado, na máquina de quem escreveu?	*quem programa*
integração	funciona junto com o resto? — o pipeline da Aula 10	*a máquina*
homologação	funciona numa cópia fiel da produção? O cliente aprova?	*time, cliente, comitê*
produção	funciona para quem usa de verdade?	*os clientes*

O caminho inteiro, automatizado, é o **pipeline de implantação** de Humble e Farley. Entre um ambiente e o próximo há um **portão** — automático no delivery; no prontuário, o último é o comitê.

Promover o artefato — não reconstruí-lo



O artefato é o mesmo do começo ao fim; o que muda é a **configuração**, que mora fora dele (Aula 09). Se a homologação aprovou o `sha256:9f2c…`, é ele que vai à produção — **e dá para conferir**.

> ⚠️ **Reconstruir para a produção é testar uma coisa e implantar outra.**

Homologação que não parece produção não homologa nada

Dados
50 pedidos de teste contra 400 mil reais

Carga
ninguém testa com o movimento de sábado à noite

Integrações
simulador de pagamento contra o serviço de verdade

Versões
um banco de dados na homologação, outro na produção

LGPD No prontuário, **dado real de paciente nunca vai para a homologação** — nem "para testar o volume". Gera-se ou anonimiza-se.

> 💡 **A última verificação sempre acontece em produção.** A pergunta é: com quantos clientes?

19/07/2024: um arquivo para todos de uma vez

04h09 UTC
a CrowdStrike envia um **arquivo de conteúdo** ao seu programa de proteção

→

21 ≠ 20
o arquivo define 21 campos; o programa espera 20 — e o validador tinha um erro

→

tela azul
o Windows trava, reinicia, trava de novo

→

05h27
o arquivo é retirado, 78 minutos depois

→

dias
cada máquina travada precisa de conserto **manual**

Não era código: era **conteúdo** — como o arquivo da Cloudflare na Aula 09. E chegou **a todos os computadores ligados, ao mesmo tempo**.

O tamanho do estrago

8,5 mi

de computadores com Windows afetados, pela estimativa da Microsoft

< 1%

das máquinas com Windows — concentrado em quem depende delas para funcionar

78 min

no ar; o conserto, máquina a máquina, levou dias

Companhias aéreas cancelaram voos, hospitais adiaram atendimentos, bancos e emissoras de TV ficaram fora do ar.

> 💡 **O que a empresa anunciou depois:** distribuir o conteúdo **de forma escalonada, começando por um canário**, e dar aos clientes **controle sobre quando** as atualizações chegam.

Mudança é a maior causa de interrupção

≈ 70%

das interrupções de serviço se devem a **mudanças num sistema em produção**

livro de SRE do Google, 2016

O que mais reduz o dano

- **implantar aos poucos** — esta aula
- detectar problemas rápido — Aula 12
- voltar atrás com segurança — Aula 12

O **raio da explosão**: quantos clientes uma mudança defeituosa atinge antes que alguém perceba. O defeito vai acontecer, apesar dos testes — **o raio é uma escolha de projeto**.

Quatro maneiras de pôr no ar

Direta

a versão nova substitui a antiga de uma vez

raio: **todos**
volta: reimplantar a anterior

Gradual

os servidores são atualizados aos poucos

raio: **cresce a cada leva**
volta: parar e reverter

Azul-verde

dois ambientes; o tráfego troca de uma vez

raio: todos, depois de testada no real
volta: **segundos**

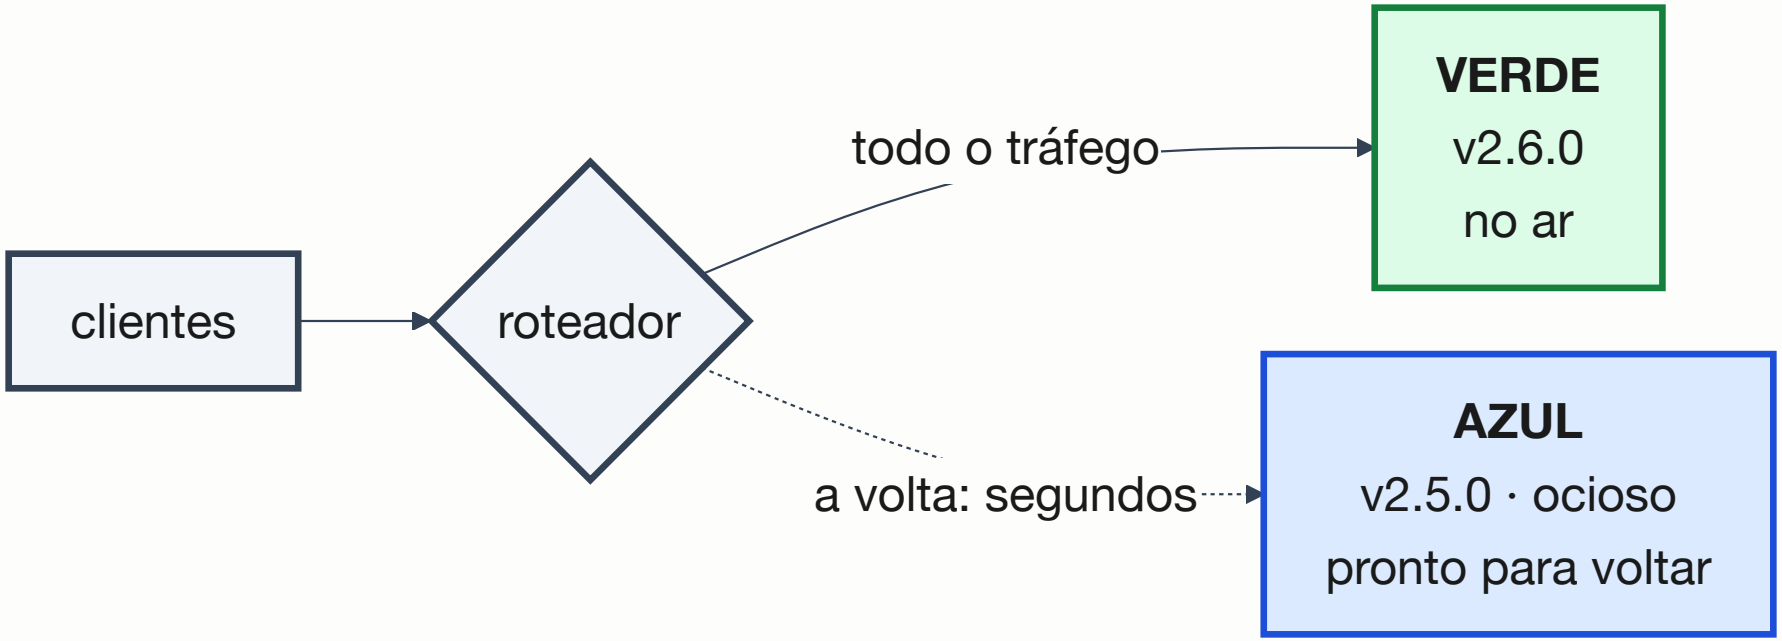
Canário

uma fatia dos clientes primeiro, observada

raio: **a fatia**
volta: tirar o canário

Do mais barato ao mais trabalhoso. **Combinar é o normal**: a estratégia se escolhe por mudança, não uma vez para sempre.

Azul-verde: a volta em segundos



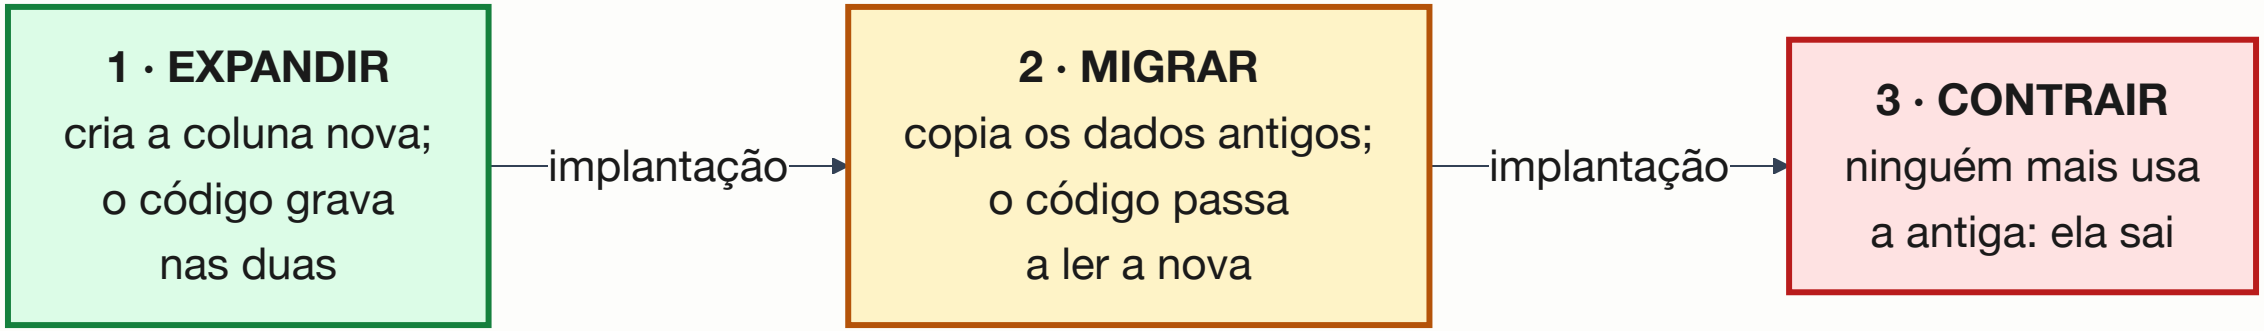
A versão nova sobe no ambiente ocioso e é verificada **com a infraestrutura da produção**. O azul nunca é desligado: se algo der errado, o roteador troca de volta. Na próxima implantação, os papéis se invertem.

Canário: alguns primeiro, todos depois



O critério se escreve **antes**: *"se os pedidos confirmados no canário ficarem 2 pontos abaixo da versão atual, ou os erros de pagamento dobrarem, volta"*. Sem ele, avança-se por otimismo e volta-se por desgaste.

O banco de dados não volta tão fácil



No canário e no azul-verde, **a versão antiga e a nova rodam juntas sobre o mesmo banco**. Renomear `endereco` de uma vez quebra os 95% que ainda rodam a antiga. Em três implantações, cada passo tem volta.

> ⚠️ **Migração destrutiva não tem canário que desfaça.** Remover, converter, apagar: a decisão de seguir sem volta se toma **antes**, por quem tem autoridade — não às 21h de sábado.

Feature flag: no ar não é ligado

```
if (flags.ligada("pagamento-pix", cliente)) {
  return pagarComPix(pedido);
}
return pagarComCartao(pedido);
```

terça
o código do Pix vai ao ar **desligado**

→

quarta
ligado para os funcionários

→

quinta
ligado para 5% dos clientes

→

semana seguinte
ligado para todos

Nenhum desses passos é uma implantação — e **cada um se desfaz desligando a flag**.

Os quatro tipos de flag

De liberação · dias a semanas

esconder o que não está pronto, ou liberar aos poucos

o Pix, ligado em etapas

De experimento · o tempo do teste

dividir os clientes em grupos e comparar

metade vê o botão "pedir de novo"

De operação · o *kill switch*

desligar ou simplificar algo às pressas

se o serviço de mapas cair, o frete volta a ser fixo

De permissão · meses a anos

liberar algo só para um grupo

o relatório de vendas, só para o dono

A classificação é de Pete Hodgson (2017). O que separa os tipos é, principalmente, **quanto tempo cada flag deve viver**.

12/06/2025: a flag que faltou

29/05
código novo no **Service Control**, região por região

→

sem flag
o trecho novo não é executado em nenhuma região; não tem tratamento de erro

→

12/06
uma política com **campos em branco** chega ao mundo todo **em segundos**

→

queda
dezenas de produtos do Google — e de quem roda sobre eles

→

40 min
o trecho novo é desligado; a recuperação total leva horas

O primeiro compromisso do relatório: **toda mudança em sistema crítico protegida por flag, desligada por padrão**.

O que o caso do Google ensina

A flag desligada por padrão

o código novo teria chegado a todas as regiões **sem ser executado** — e seria ligado aos poucos

O dado também é mudança

a implantação do código foi gradual; o dado que disparou o defeito, não — chegou ao mundo todo em segundos

Aula 09

Cloudflare: um arquivo de configuração

esta aula

CrowdStrike: um arquivo de conteúdo

esta aula

Google: uma política replicada

Três vezes no bloco: **configuração e dados precisam da mesma cautela que o código**.

Flag é dívida com prazo

2

flags: **4** combinações possíveis

10

flags: **1.024** combinações — ninguém testa todas

1

flag reaproveitada bastou para a Knight Capital, na Aula 09

Dono e data

a tarefa de remover entra no backlog no dia da criação

Limite

o número de flags ativas tem teto, como um estoque

Nunca reaproveitar

flag velha não ganha significado novo

Escolher pelo risco da mudança

	impacto baixo	impacto médio	impacto alto
prob. alta	gradual	canário	canário com flag, fora do pico — ou rever a mudança
prob. média	direta	gradual ou azul-verde	canário com flag
prob. baixa	direta	direta	**azul-verde ou canário, com a volta pronta**

Probabilidade cresce com o tamanho e a novidade da mudança. **Impacto**, com clientes, dinheiro, dado sensível — e **irreversibilidade**. É a matriz da leitura *Risco*, e a mesma armadilha: probabilidade baixa com impacto alto **não é "direta"**.

No delivery

Mudança	Probabilidade	Impacto	Como implantar
erro de digitação no cardápio	baixa	baixo	**direta** a qualquer hora
frete por bairro, não por distância	média	médio	**azul-verde** fora do pico
trocar o provedor de pagamento	média	**alto**	**canário com flag** funcionários → 5% → 25% → todos

No pagamento, o provedor antigo fica **a um clique** até a mudança chegar a 100% e estabilizar.

As cinco métricas DORA

Vazão

- **tempo de espera da mudança** — do commit à produção
- **frequência de implantação**
- **tempo de recuperação** de implantação com falha

Instabilidade

- **taxa de falha de mudança** — implantações que exigem reverter ou corrigir às pressas
- **taxa de retrabalho** — implantações não planejadas, para corrigir incidente

Cinco desde 2024: entrou a taxa de retrabalho, e o tempo de recuperação passou para a vazão. A leitura *Qualidade que se mede* traz as quatro clássicas.

Velocidade e estabilidade andam juntas

Desempenho mais alto · DORA 2024

- commit → produção em **menos de 1 dia**
- recuperação em **menos de 1 hora**
- taxa de falha de cerca de **5%**

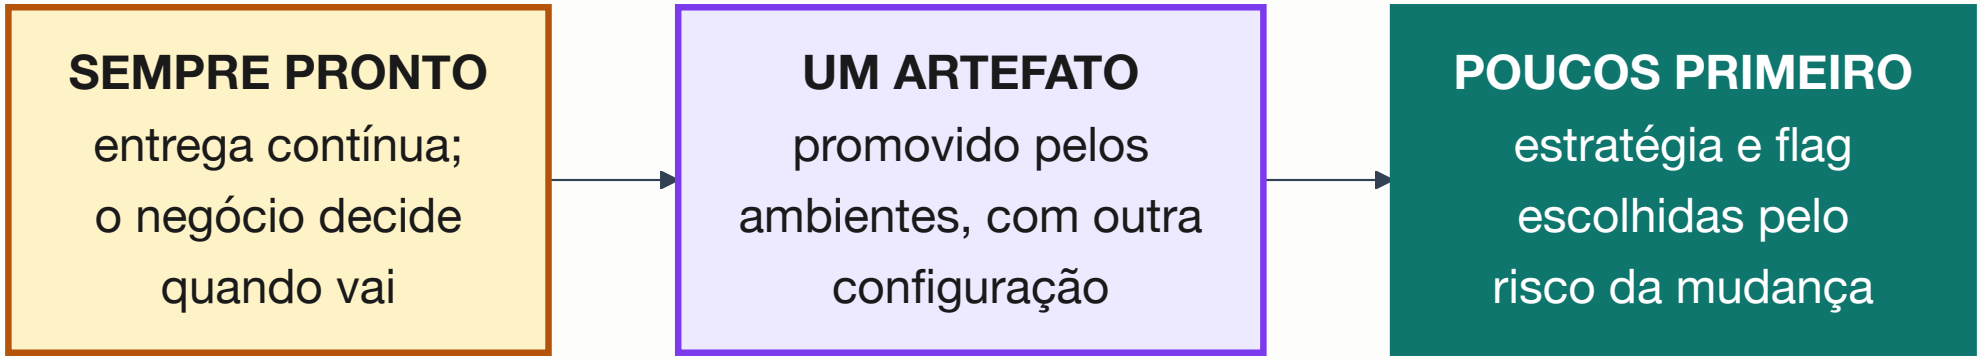
Desempenho mais baixo · DORA 2024

- commit → produção em **1 a 6 meses**
- recuperação em **1 semana a 1 mês**

Ano após ano, quem entrega mais rápido tende a ser também **mais estável** — porque entrega em pedaços pequenos, verificados e com volta.

> ⚠️ **As métricas DORA também viram meta** — o próprio DORA avisa. Leem-se **juntas**, **por aplicação**, para o time comparar a si mesmo — nunca para ranquear times.

O que esta aula deixa no lugar



A versão nova está no ar, para 5% dos clientes, com o critério escrito. Falta **enxergar** o que acontece em produção — e saber o que fazer quando o critério é violado.

➡️ Próxima aula

Aula 12 — Operação: observabilidade e manutenção

Está no ar.

Como saber se está tudo bem —

e o que fazer quando não está?