

Operação: Observabilidade e Manutenção

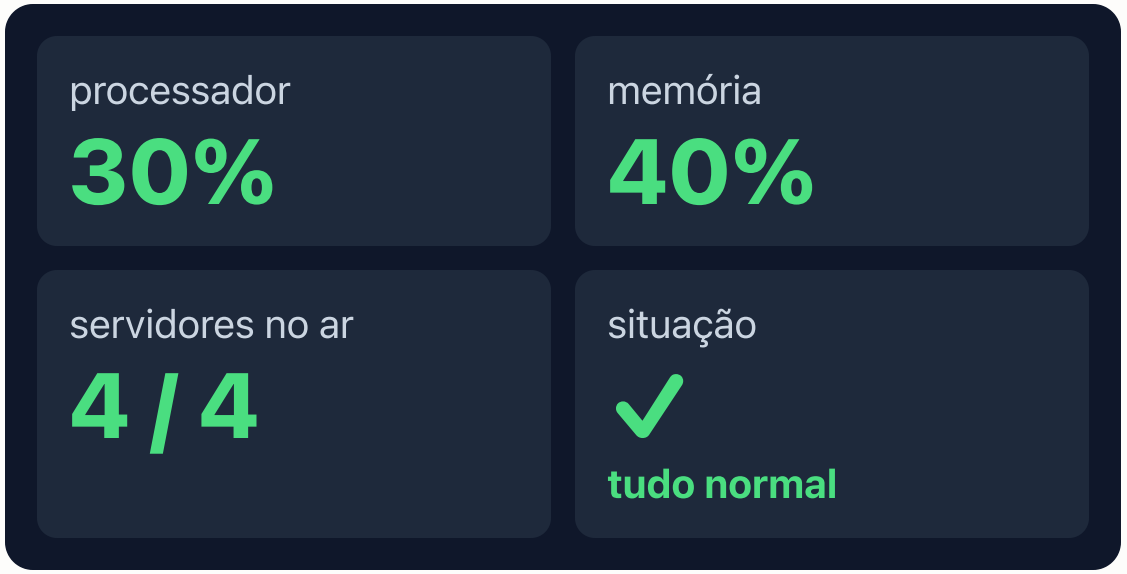
Aula 12 · Bloco 3 — Do Código à Produção

Está no ar. Como saber se está tudo bem — e o que fazer quando não está?

🎯 Nesta aula

1. **Monitorar a máquina não é observar o serviço**
2. **Logs, métricas e rastros** — cada um para uma pergunta
3. **SLO**: quanto de falha é aceitável, e quando acordar alguém
4. **Incidente**: restaurar primeiro, entender depois
5. **Postmortem sem culpa**
6. **Manutenção**, evolução e **dívida técnica**

O painel verde



1 em 3

pagamentos por Pix **não confirma** — há dois dias.

Quem descobriu: o dono do restaurante, lendo as reclamações no Instagram.

O painel respondeu tudo o que alguém perguntou a ele. **Ninguém tinha perguntado se os clientes conseguiam pagar.**

Monitorar × observar

Monitoramento

painéis e alertas para as perguntas **que se sabia de antemão**

"o servidor está de pé?"

Observabilidade

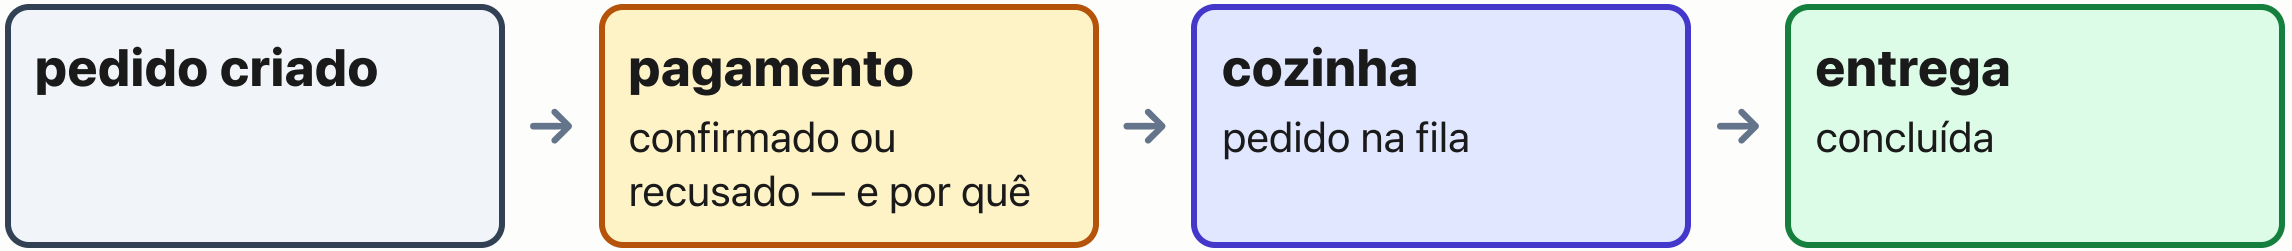
responder perguntas **que ninguém previu**, sem escrever e implantar código novo

"por que só o Pix de um banco falha, e só depois das 19h?"

O termo vem da teoria de controle (Kálmán, 1960): o quanto o estado interno de um sistema se deduz **do que ele emite**. A definição para software é de Charity Majors.

> 🔎 **A pergunta que orienta tudo:** o que eu preciso saber para responder *"o serviço está bom?"* **sem perguntar a ninguém**?

Instrumentar o negócio, não só a máquina



O Pix falhando

apareceria em **15 minutos**, e não em dois dias

A funcionalidade não usada

da Aula 08 aparece: o relatório por bairro foi aberto **3 vezes em um ano**

Medir uso é o que transforma *"acho que ninguém usa"* numa decisão: manter, melhorar ou remover.

Três sinais, três perguntas

📜 Log

um evento, com hora e detalhes

o que aconteceu com este pedido, exatamente?

custo: cresce com o volume

📈 Métrica

um número agregado ao longo do tempo

como está o sistema, e como estava ontem?

custo: baixo e fixo

🧵 Rastro

o caminho de uma requisição por todos os serviços

onde o tempo foi gasto, ou o erro aconteceu?

custo: médio — guarda-se uma amostra

Nenhum substitui os outros. O padrão aberto para emiti-los é o **OpenTelemetry** (2019): instrumenta-se uma vez, e os sinais vão para qualquer ferramenta.

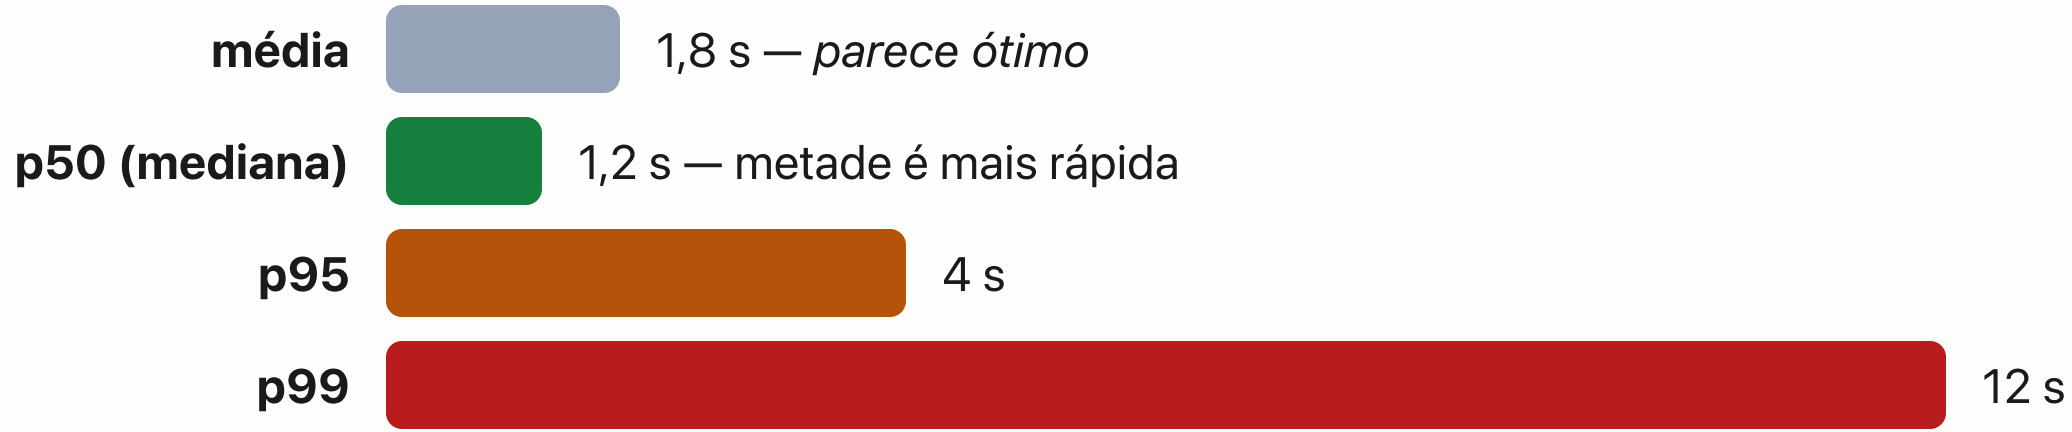
O log estruturado

```
{"hora": "2026-11-21T19:42:07Z", "evento": "pagamento_recusado",
 "pedido": 4471, "meio": "pix", "provedor": "banco-x",
 "motivo": "tempo_esgotado", "versao": "2.6.0", "rastro": "a3f9c21e"}
```

"Quantos Pix foram recusados por tempo esgotado, por banco, desde a 2.6.0?" vira **consulta**, não investigação. O campo `versao` liga a produção à baseline da Aula 09.

> ⚠️ **Log não é lugar de dado pessoal.** Sem nome, telefone, CPF — o identificador do pedido basta. No prontuário, diagnóstico em log é dado de saúde copiado, e a LGPD vale para a cópia. E log costuma ser lido por mais gente que o banco: lembre a Aula 10.

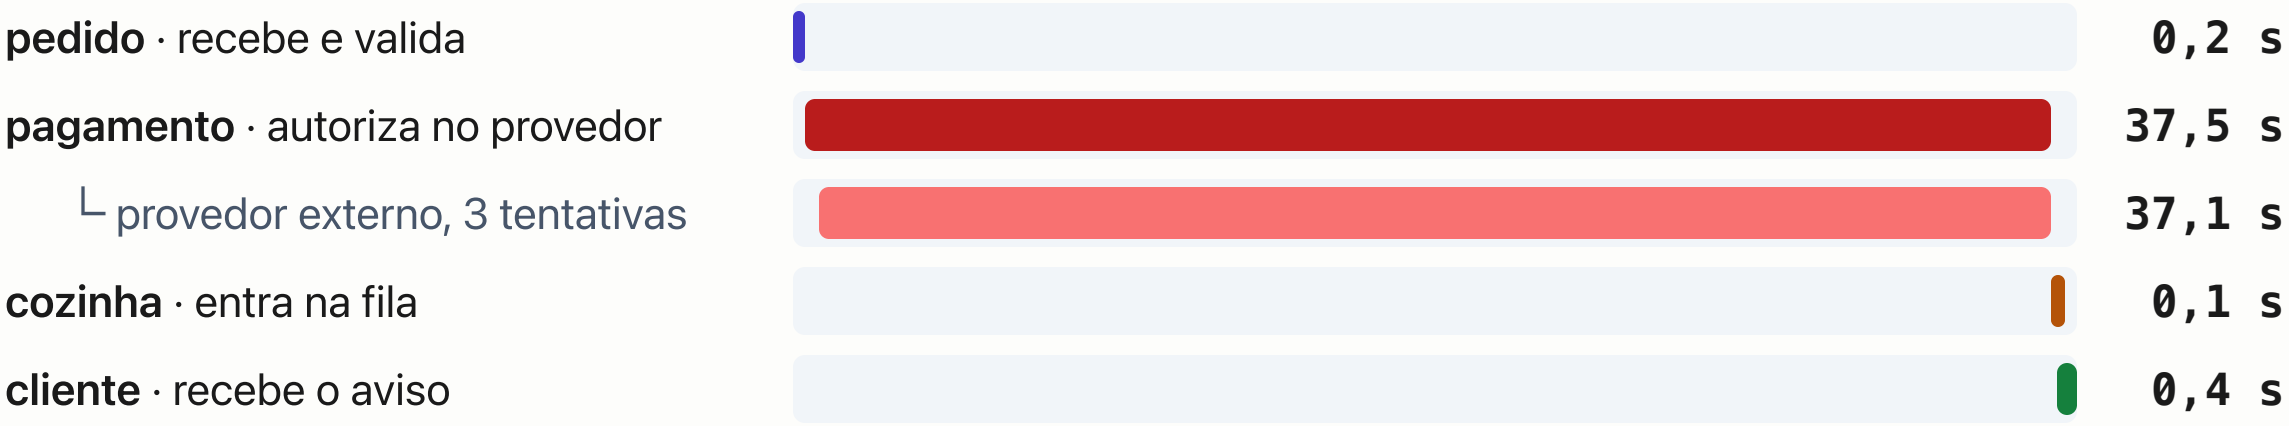
A média esconde



Tempo de confirmação do pedido no delivery. **Um em cada cem clientes espera 12 segundos** — e desiste. Tempo se mede em **percentis**.

> 💡 O SRE do Google alerta para a cadeia: o **pior 1%** de um serviço interno vira o tempo **típico** de quem está na ponta.

O rastro: o que aconteceu com este pedido?



Pedido 4471 · rastro `a3f9c21e` · 38,4 s no total. Em vez de *"está lento"*: **"o provedor de Pix do banco X leva 37 s, e o nosso código tenta três vezes"**.

É a resposta à pergunta que a **Aula 04** deixou na arquitetura orientada a eventos.

Por onde começar: os quatro sinais de ouro

Latência

quanto tempo leva para atender

p95 da confirmação

Tráfego

quanta demanda chega

pedidos por minuto

Erros

a proporção que falha

pagamentos recusados por erro nosso

Saturação

o recurso mais apertado, perto do limite

conexões ocupadas no banco

A recomendação é do livro de SRE do Google para qualquer serviço novo: **se só der para medir quatro coisas, meça estas**.

SLI, SLO, SLA

SLI · indicador

uma proporção de eventos bons

Pix confirmados em até 30 s ÷ pedidos com Pix

SLO · objetivo

o alvo, numa janela de tempo

99,5% nos últimos 30 dias — **o time persegue**

SLA · acordo

um contrato, com consequência

o provedor devolve parte da tarifa abaixo de 99% — **mais folgado que o SLO**

Quem promete 99% em contrato quer o próprio alvo em 99,5%: **para descobrir o problema antes de pagar a multa**.

Por que não 100%?

99%	99,5%	99,9%	99,99%
7 h 12 min fora do ar em 30 dias	3 h 36 min	43 min	4 min 19 s

O livro de SRE do Google: **100% quase nunca é o alvo certo**. É impossível, cada "nove" custa muito mais que o anterior — e o cliente nem percebe, porque o próprio celular falha mais que isso.

O orçamento de erro



Delivery: 6.000 pedidos com Pix por mês, SLO de 99,5% → **30 pedidos por mês podem falhar**. É isso o orçamento.

Enquanto há orçamento

o time implanta à vontade — com as estratégias da Aula 11

Quando o orçamento acaba

param as funcionalidades novas; o esforço vai para a confiabilidade

Uma discussão de opinião — *"estamos indo rápido demais?"* — vira **uma conta combinada antes**.

Alerta é para acordar alguém

🔔 Alerta — exige ação, agora

- Pix confirmados abaixo de 95% por 10 min
- o ritmo de falhas esgota o orçamento do mês **em dois dias**

pelo **sintoma** que o cliente sente

📊 Painel — sem ação imediata

- processador acima de 80%
- um pedido isolado que demorou
- o orçamento acabando em seis meses

a **causa**, para quem investiga

⚠️ **"Todo alerta precisa exigir ação"** — livro de SRE. Alerta irrelevante treina o time a silenciar o canal, e o alerta importante chega no meio dos outros. É o teste instável da Aula 10, de novo.

Incidente, problema, mudança

Incidente

interrupção não planejada, ou queda de qualidade

os Pix não confirmam

Problema

a causa de um ou mais incidentes

o provedor demora, e o nosso código desiste cedo

Mudança

qualquer alteração no que está em produção

a 2.6.0, às 19h40

Vocabulário do ITIL (leitura *Governança*). O incidente é o **risco que se materializou** (leitura *Risco*).

> 🔎 Cerca de **70%** das interrupções vêm de uma mudança. A primeira pergunta é a da Aula 09: **o que mudou?**

O mesmo sábado, bem conduzido

19h40
a 2.6.0 vai ao ar num canário de 5%

→

19h52
alerta: canário 9 pontos abaixo, por 10 min

→

19h53
Bruno **declara o incidente** e assume o comando

→

19h55
o que mudou? — a 2.6.0, há 15 min

→

19h56
canário a 0% — às 20h01, tudo normal

Alerta
pelo sintoma

Critério
de volta, escrito antes

Volta pronta
o canário da Aula 11

Restaurar
antes de entender

Às 19h56, **ninguém sabia qual era o defeito**. Não precisava saber: a causa ficou para segunda-feira.

Do alerta ao aprendizado



Restaurar primeiro, entender depois. Procurar o defeito com o sistema fora do ar é gastar o tempo do cliente na curiosidade do time.

Reverter
o artefato anterior está guardado

Desligar a flag
da funcionalidade nova

Trocar o tráfego
de volta para o azul

Zerar o canário
todos na versão anterior

O plano de volta cabe em quatro perguntas

Pergunta	No delivery
quando decidimos voltar?	pedidos confirmados 2 pontos abaixo da versão anterior, por 10 min
quem decide?	quem estiver de plantão, sem consultar ninguém
como se volta?	canário a 0%; o banco de dados não foi alterado
quanto leva?	cerca de 3 minutos

> ⚠️ **A primeira linha é a que sempre falta.** Sem critério escrito, a decisão de voltar é tomada **por desgaste**: tenta-se consertar, espera-se mais um pouco — e a conversa sobre reverter só acontece depois de uma hora.

Papéis e runbook

Comandante

coordena, decide, delega — **não põe a mão no sistema**

Operação

age no sistema

Comunicação

avisa o dono e os clientes, para ninguém interromper quem opera

Runbook — pedidos confirmados abaixo do normal

1. A queda é geral ou de um meio só?
2. Houve implantação ou mudança de flag nas últimas 2 h? → **volte a mudança** e confira em 5 min
3. O provedor de pagamento está com incidente? → ligue **"pagamento-somente-na-entrega"** e avise o dono
4. Nada disso: declare incidente e chame a segunda pessoa

Última revisão: 2026-11-10 · Dono: Ana

Papéis do modelo do Google, inspirado nos bombeiros. O runbook é **item de configuração** da Aula 09.

Tempo de recuperação = descobrir + decidir + agir



Descobrir

encurta com a **observabilidade** — o alerta pelo sintoma

Decidir

encurta com o **critério escrito** e o plano de volta

Agir

encurta com as **estratégias da Aula 11** — volta em minutos

Quando o **tempo de recuperação** do DORA está alto, é por um desses três que se começa.

31/01/2017: o banco de dados errado

23h30 UTC
um engenheiro do **GitLab** reconstrói a réplica de um banco sobrecarregado

→

rm -rf
apaga a pasta de dados — no servidor **principal**, não na réplica

→

o backup
falhava havia tempo; o e-mail de aviso era **rejeitado**

→

a sorte
uma cópia manual de 6 h antes, feita para testes

→

ao vivo
a recuperação transmitida no YouTube

300 GB
apagados em um ou dois segundos

6 h
de dados perdidos — 5 mil projetos, 700 contas

18 h
com o GitLab.com fora do ar

Backup que nunca foi restaurado é uma hipótese

O que falhou em silêncio

- o backup diário, por incompatibilidade de versão
- o aviso de falha, rejeitado pelo servidor de e-mail
- os outros mecanismos, que não cobriam aquele servidor

O que o postmortem listou

- replicação frágil
- **backups que ninguém testava**
- falta de dono para a restauração

publicado 10 dias depois — sem buscar culpado

É o painel verde da abertura em outra roupa: **um mecanismo que falha sem que ninguém fique sabendo**.

Postmortem sem culpa

O que ele procura

as **causas contribuintes**, sem acusar pessoa ou time — e parte de que **todos agiram com boa intenção**, com o que sabiam na hora

livro de SRE do Google

Por que funciona

quando o erro é punido, as pessoas **escondem informação**, e o próximo incidente demora mais para ser entendido

John Allspaw, Etsy, 2012 — a cultura justa

Trocar o engenheiro do GitLab deixaria tudo no lugar: o comando destrutivo à mão, o principal parecido com a réplica, o backup mudo. **O próximo engenheiro cansado encontraria o mesmo sistema.**

> ⚠️ **"Erro humano" é o começo da investigação, não o fim.** A pergunta seguinte: por que o sistema permitiu que a falta de atenção de uma pessoa derrubasse tudo?

O que um postmortem contém

Postmortem — Pix não confirmado, 21/11

Resumo — duas frases: o que houve, qual o impacto

Impacto — 14 pedidos, 21 min, metade do orçamento

Linha do tempo — com hora: começo, alerta, volta

Causas contribuintes — quase nunca há uma só

O que funcionou — para manter

Ações — cada uma com **dono e prazo**, no backlog

Quando escrever — os gatilhos do SRE:

- **dano visível ao cliente**
- **qualquer perda de dados**
- **volta ou troca de tráfego**
- **resolução demorada**
- **falha de monitoramento**

Incidentes que **se repetem** são um **problema**: é ali que o Six Sigma da Aula 08 cabe — na operação, com repetição e medição.

O sistema que não muda fica pior

Mudança contínua

um sistema em uso precisa ser adaptado o tempo todo, ou fica cada vez menos satisfatório

→ a manutenção **não é opcional**

Complexidade crescente

a cada mudança, a complexidade aumenta — a menos que alguém trabalhe para reduzi-la

→ e o custo dela **cresce**

Duas das leis de Meir Lehman, dos anos 1970 — ainda a melhor descrição do que acontece depois da entrega.

> ⚠️ **Quando o projeto acaba, alguém precisa ficar com o sistema.** Sem dono, sem plantão e sem runbook, o primeiro incidente leva dias, e não minutos.

Os quatro tipos de manutenção

Corretiva

consertar defeito

o frete arredondado errado

Adaptativa

acompanhar o ambiente: lei, integração, plataforma

o provedor de Pix muda a API

Perfectiva

melhorar ou acrescentar o que se pede

o filtro por bairro

Preventiva

reduzir o risco futuro

testar a restauração do backup



⚠️ Contrato que cobre **só a corretiva** deixa de fora a maior parte do trabalho.

Dívida técnica

	imprudente	prudente
deliberada	*"não temos tempo para pensar no desenho"*	*"duplicamos o frete para sexta, e unificamos na semana 3"* — **registrada, com dono**
inadvertida	*"o que é separar em camadas?"*	*"agora que construímos, sabemos como deveria ter sido"*

Cunningham (1992): um pouco de dívida acelera, **desde que paga logo**; o juro é o tempo perdido a cada mudança. O quadrante é de Fowler (2009). Só o verde é uma **decisão**, no sentido da Aula 07.

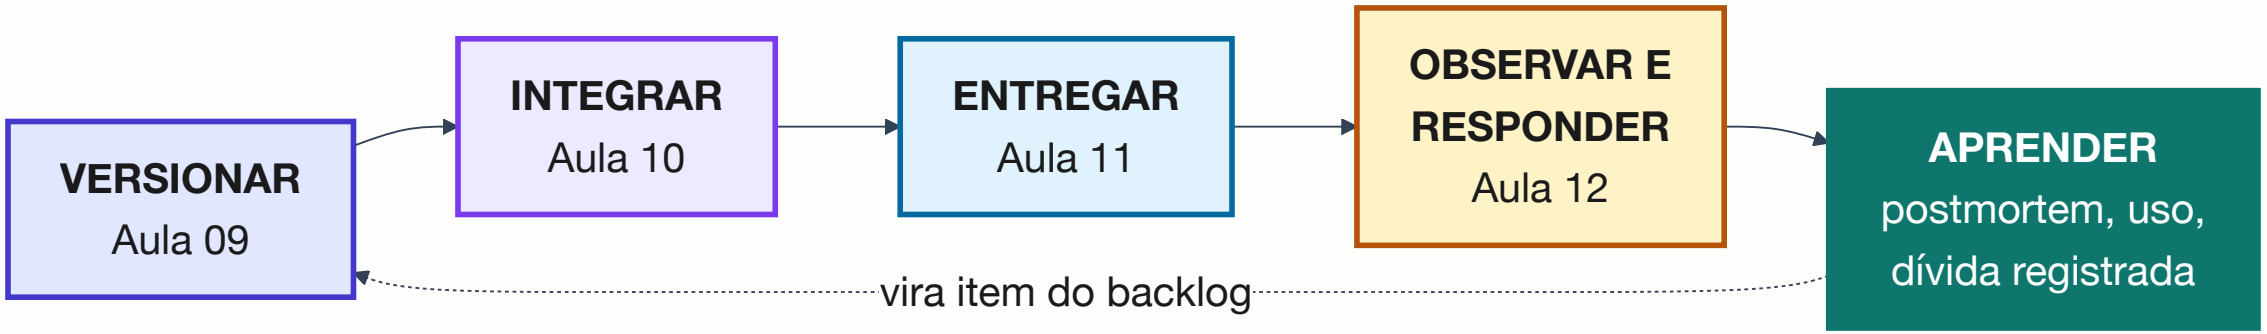
No bloco: a flag que ficou (Aula 11), o teste em quarentena para sempre (Aula 10) — e a funcionalidade que ninguém usa: **remover também é manutenção**.

Traduzir para quem paga

No vocabulário técnico	No vocabulário do dono do restaurante
"o frete está duplicado em três lugares"	*"cada mudança no frete leva uma semana em vez de um dia"*
"precisamos refatorar antes"	*"duas funcionalidades agora e nenhuma em março, ou uma agora e quatro até março"*
"a biblioteca de pagamento está desatualizada"	*"em março ela para de receber correção de segurança, no meio do pagamento"*

A dívida só disputa prioridade quando é traduzida em tempo, dinheiro ou risco. E nem toda se paga: sistema que será desligado em um ano não justifica reescrever o frete.

O bloco inteiro em uma volta



O que se aprende em produção — o incidente, a funcionalidade que ninguém usa, a dívida que cobra juros — volta como **item do backlog**, e a próxima mudança percorre o mesmo caminho.

🏁 Doze aulas, um fio só

A mudança é o objeto de trabalho
da gestão de projetos.

O escopo muda, o plano muda, o time muda,
o sistema muda depois de entregue —
e alguém precisa conduzir cada mudança.

📚 As **leituras complementares** continuam o caminho.